《BERT 与逻辑的结合》

YKY

October 15, 2021

- 我比较熟悉 经典逻辑 AI，写过 逻辑引擎
- 但我没有 BERT/GPT 的实战经验
- 今天我们考虑一下 结合 BERT/GPT 和 逻辑引擎 的可能，有什么优势？

0. 我的策略

- 将 BERT/GPT 解释为一种 逻辑／符号演算的系统
- 将 逻辑结构 impose 到新的 BERT/GPT 模型
  (它不再是语言模型，而是逻辑模型)
- 利用我们对逻辑 AI 的理解，
  改良这新的模型，
  从逻辑角度理解参数的意义
- 如果不这样做，BERT/GPT 仍然是 “black box”，
  那就很难想出改良的思路

1. 逻辑 + BERT/GPT 混合的好处

似乎 有一些优势，但我暂时未能提出一个很有说服力的 说法：

- Long-term memory as a separate module
- Explicitly edit memories
- Make the BERT/GPT model more transparant

2. List of things desirable regardless of logi-calization

由于我比较熟悉 logic，我不知有没有不用 logic 的更好方法.... 各位同学可以想想。

- 希望 BERT/GPT 的 inference 更 robust
- BERT/GPT 直接学习知识的能力 ("learn by being told")
  那就可以将这 AI 放到人类工作环境，透过工作教导 AI
  似乎需要「长期记忆」(LTM)
  但如果这 LTM 不是一个独立 module,
  可能比较麻烦?

3. Transformer 的 equi-variance

(见 知乎 文章)

4. Logic AI 的基本架构

经典 logic-based AI 的架构，其实很简单的：

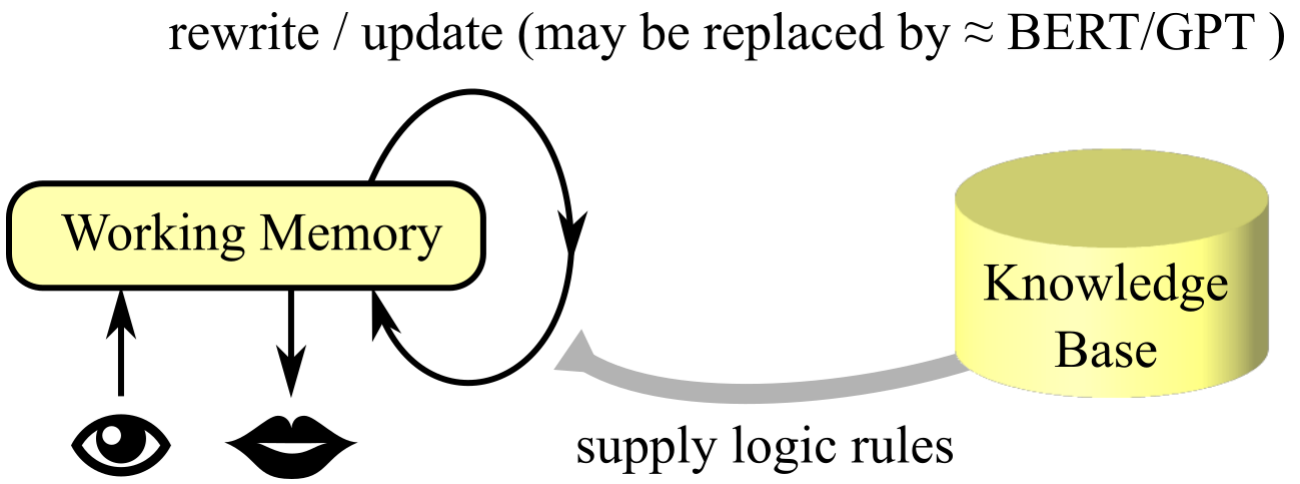

(1)

重点是我们将 update loop 那个函数 看成是 对应于 BERT/GPT.

借用 **认知科学** 术语，Working Memory = 系统的 **状态** (state),
例如：

我很肚饿 ∧
冰箱没有食物 ∧
现在是午夜 3 点 ∧
商店已经打烊 ∧
.... ∧ ....

换句话说，状态 是 一堆 逻辑命题 的 **集合**

Working Memory 的 状态更新 是靠 逻辑 rules 的作用，
例如：$\forall x.\ \text{human}(x) \rightarrow \text{mortal}(x)$

5. 神经科学 带来的的启发

- 一直以来，人们觉得 大脑的 KR（knowledge representtation, 知识表述）跟符号逻辑 肯定是大相迳庭的

6. Seq-seq-2-seq

我提出：BERT/GPT 可能是一种 “seq-seq → seq” architecture.

- 逻辑 与 自然语言 之间大约有这样的对应：
  句子 ≈ 命题，词语 ≈ 概念，
  命题 = 多个概念的 concatenation
- 从 强化学习的角度看：
  状态 (state) = 命题集合，
  transition function：命题集合 → 命题集合
- 命题集 = sequence of 命题，
  命题 = sequence of concepts，
  所以 状态 = 命题集 = sequence of sequences (seq-seq)
- transition function: seq-seq → seq-seq

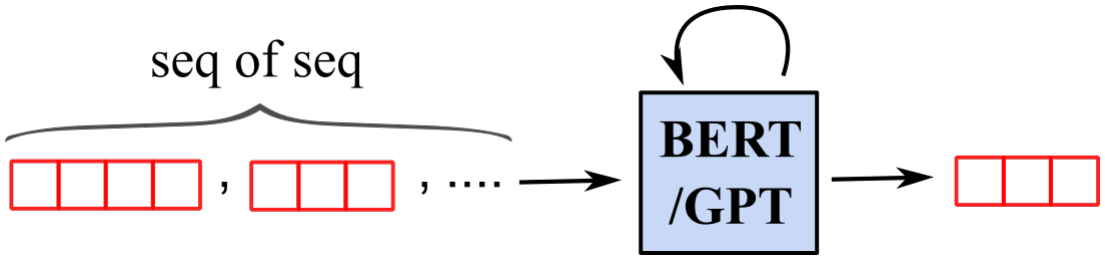

(2)

- 每次状态更新时，我们可以只增添一个命题，
  「遗忘」另一个命题

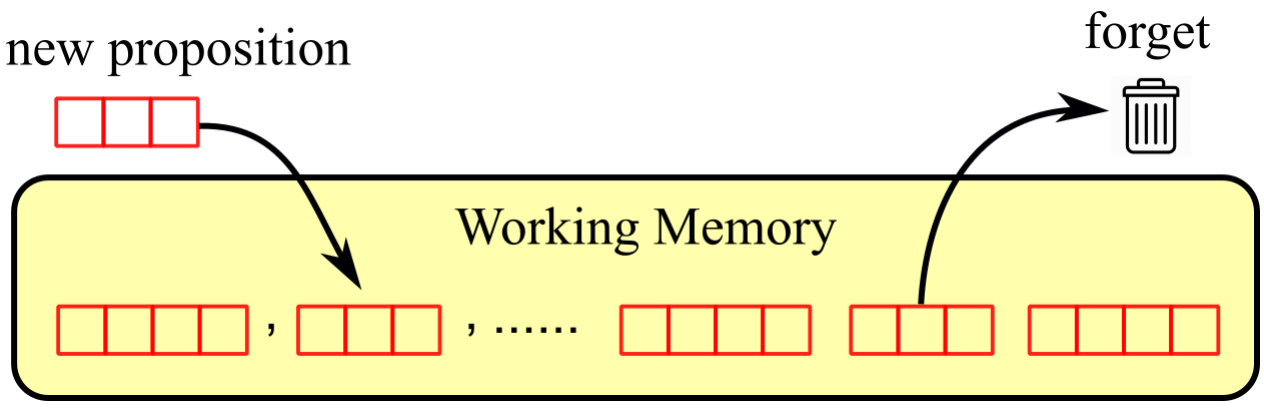

(3)

- 因此 transition function 只需是 seq-seq → seq

长期记忆 可以这样实现：

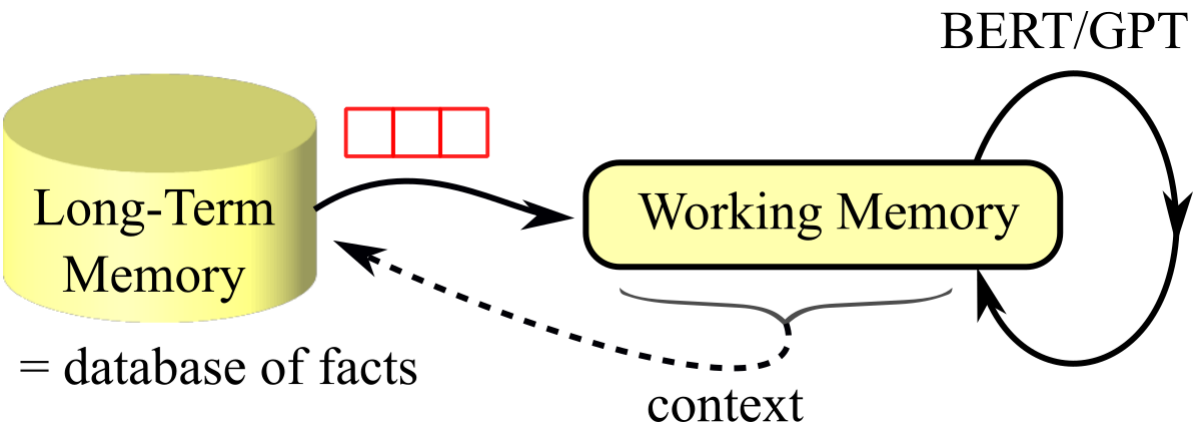

(4)

它透过 Working Memory 的内容 决定 输出什么 命题，其机制类似 **推荐系统** (recommender systems).

已经有类似的研究，利用 BERT/GPT 提取 **知识图谱** 资料 (COMET).

这是用 BERT 训练 AGI 的一个可能的做法：

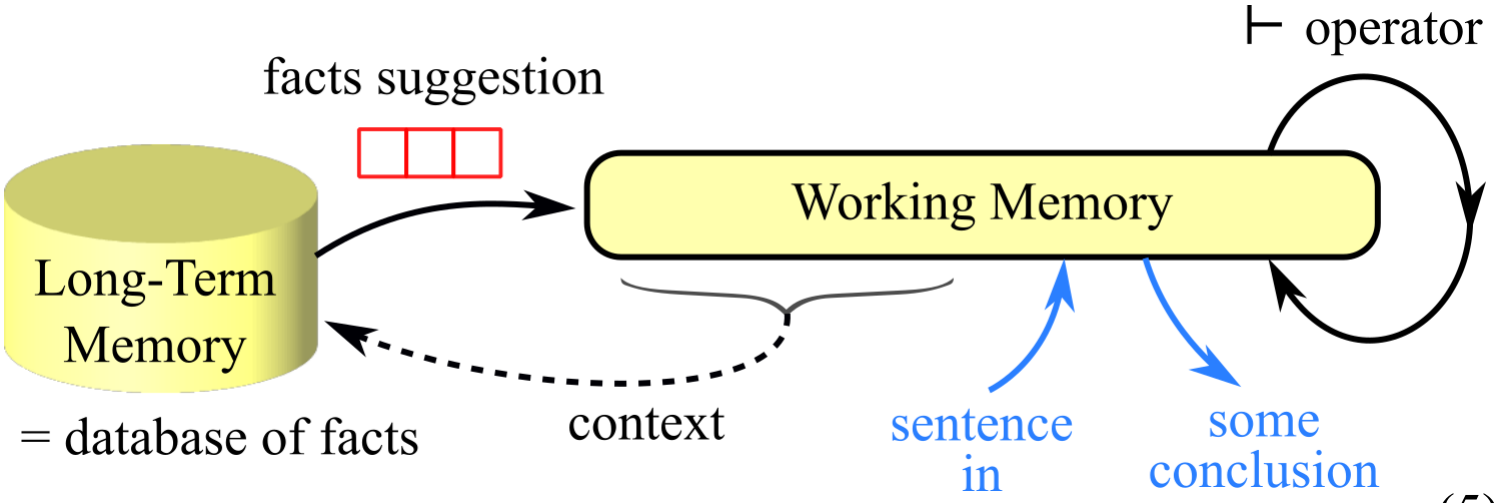

(5)

7. 强化学习的考虑

- 从 强化学习 的角度看，
  每个 iteration 要输出一个 **命题** = 几个**词语**

- 这 输出 对应于 强化学习的 **actions**
- 换句话说，每个 action = 一个命题 = 几个词语
- 所以，我们需要输出 在 actions 之上的 **概率分布**
  （而不仅仅是一个 action）
- 数学上 这是 $\{\text{所有可能命题}\} \to \mathbb{R}$ 的空间 $= \mathbb{R}^{|X|}$
- 这个空间异常大，我初时觉得 没有希望在计算机上表达
- 但 Dr 肖达 解释了一个很有效率的方法，
  用 矩阵乘法 将输出 由 1024 维 **扩张**到 25000 维：

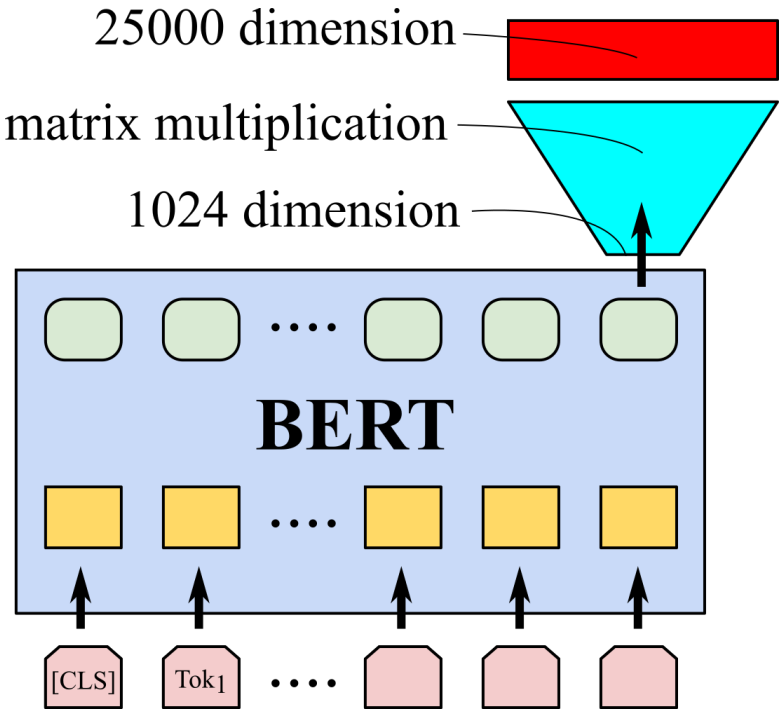

(6)

- 但这个做法，其实输出的 只有 1024 个 **独立**的份量

例如，「天气很热，我在家中整天_____」
- 流汗
- 吃冰淇淋
- 喝冰水

- 不穿衣服
- 开冷气....

「女朋友说分手，我觉得_____」

- 很伤心
- 如释重负
- 很气愤
- 很妒忌....

「电脑的键盘没反应，可能是因为_____」

- 未插线
- 电线断了
- 档机了
- 视窗未 active ....

考虑这些例子，我暂时不清楚 1024 维 够不够用。
以 1024-dim 表示所有 **概念** 是足够的（cf. Word2Vec）
但未知它能不能够 表示所有常见的 **multi-modal** 概率分布。

8. BERT/GPT 是符号演算系统

Few-shot generalization.

9. Variable binding

量词 $\forall X$ 将 变量 X 「捆绑」，意思是在 $\forall X$ 的 **有效范围** (scope) 内，所有 X's 的取值 必须是**一样**的：

$$\forall X, Y, Z.\ \ \text{grandfather}(X, Z) \leftarrow \text{father}(X, Y) \wedge \text{father}(Y, Z) \quad (7)$$

用 self-Attention 表达，即是将 输入层 的一个 token “copy” 到输出层的 另一个 token 位置。(可以对比下图:)

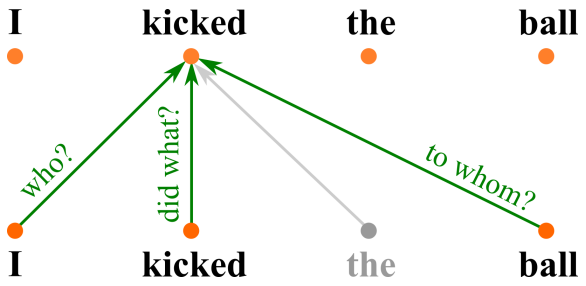

(8)

10. Relation algebra

Relation algebra 似乎是一种更 接近 自然语言 的 逻辑形式:

$$\underset{\text{爸爸}}{F} \quad \underset{\text{的}}{\circ} \quad \underset{\text{爸爸}}{F} \quad \underset{\text{是}}{=} \quad \underset{\text{爷爷}}{G} \tag{9}$$

$$\begin{gathered} \underset{\text{Albert}}{a} \quad \underset{\text{是 爸爸 of}}{F} \quad \underset{\text{Bob}}{b} \\ \underset{\text{Bob}}{b} \quad \underset{\text{是 爸爸 of}}{F} \quad \underset{\text{Charles}}{c} \end{gathered} \tag{10}$$

$$\underset{\text{Albert}}{a} \quad \underset{\text{是}}{(} \underset{\text{爸爸 of}}{F} \quad \underset{}{\circ} \quad \underset{\text{爸爸 of}}{F} \underset{}{)} \quad \underset{\text{Charles}}{c} \tag{11}$$

$$\underset{\text{Albert}}{a} \quad \underset{\text{是 爷爷 of}}{G} \quad \underset{\text{Charles}}{c} \tag{12}$$

其实 上例中 (9) $\Rightarrow$ (10) 混合了 predicate logic.
Relation algebra 只描述 **关系** 之间的代数，
但不涉及 关系**内**的元素。

这个例子表明 BERT/GPT 用的可能是
一种更为 flexible 的 **rewriting system**（改写系统）。

注意：relation algebra 不同于 relational algebra, 后者是 描述 database 用。

11. 自动 产生 / 运行 代码

我们可以**生成**一些 programming problems，
而且 100% 肯定 答案是正确的。

逻辑上的 ∀ **泛化** 可以保证
学习出来的 规则 是正确的，
因为它很有可能是 **minimum description length** (MDL).

但逻辑引擎的问题是：
它没有很高效率的 **learning algorithm** （不像 深度学习）

问题是 BERT/GPT 可以怎样「帮助」逻辑引擎 的学习...?